

## Lista 2

### Tópicos Especiais em Engenharia de Computação

Eric Calasans de Barros    Fagner Ferreira

16 de outubro de 2017

# Questão 1

Sejam  $\bar{x}_1 = 230,0$ ,  $s_1 = 10,7$ ,  $\bar{x}_2 = 225,5$ ,  $s_1 = 10,7$  e  $s_2 = 15,4$ , para  $\sigma_1^2 = \sigma_2^2$ , calcularemos um **intervalo de confiança(IC)** de 95% ( $\alpha = 0.05$ ) para a diferença das médias  $\mu_1 - \mu_2$ . Se

$$s = \frac{\sigma}{\sqrt{n}}$$

então:

$$Z = \frac{\bar{x} - \mu}{\sigma/\sqrt{n}} = \frac{\bar{x} - \mu}{s} \Rightarrow \mu = \bar{x} \pm Z * s$$

# Questão 1

Dizer que a média está contida num determinado IC significa que  $\mu = \bar{x} \pm Zs$ . Assim, para a diferença das médias temos que:

$$\begin{aligned}\mu_1 - \mu_2 &= (\bar{x}_1 \pm Zs_1) - (\bar{x}_2 \pm Zs_2) \\ &= \bar{x}_1 \pm Zs_1 - \bar{x}_2 \pm Zs_2 \\ &= (\bar{x}_1 - \bar{x}_2) \pm Z(s_1 - s_2)\end{aligned}$$

Como procuramos um IC bilateral temos que  $\frac{\alpha}{2} = 0.025$ . Pela simetria da curva de distribuição Normal temos que  $|Z_\alpha| = |Z_{1-\alpha}| \Rightarrow |Z_{0,025}| = |Z_{0,975}|$ .

# Questão 1

Com a ajuda do software estatístico RStudio:

```
qnorm(.975)
```

```
## [1] 1.959964
```

Assim temos:

$$\mu_1 - \mu_2 = (230,0 - 225,5) \pm 1,96(10,7 - 15,4) = 7,5 \pm 9,2$$

## Questão 2

Sejam  $n_1 = 20$ ,  $\bar{x}_1 = 510$ ,  $s_1^2 = 20$  e  $n_2 = 15$ ,  $\bar{x}_2 = 620$ ,  $s_2^2 = 30$  com  $\sigma_1^2 \neq \sigma_2^2$ , deseja-se calcular:

a) **Um intervalo de confiança de 95% para  $\mu_1 - \mu_2$**

Como  $n \leq 30$  em ambos os casos, usamos uma distribuição **t-Student**. Assim, para  $\sigma_1^2 \neq \sigma_2^2$  temos que

$$\mu_1 - \mu_2 = (\bar{x}_1 - \bar{x}_2) \pm t_{df} \sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}$$

onde

$$d_f = \frac{\left(\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}\right)}{\frac{\left(\frac{s_1^2}{n_1}\right)^2}{\frac{n_1}{n_1}-1} + \frac{\left(\frac{s_2^2}{n_2}\right)^2}{\frac{n_2}{n_2}-1}} = \frac{(20/20 + 30/15)^2}{\frac{(20/20)^2}{19} + \frac{(30/15)^2}{14}} = 26$$

## Questão 2

a) cont.

$$\mu_1 - \mu_2 = (\bar{x}_1) - \bar{x}_2) \pm t_{0,975,26} \sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}$$

Pelo **RStudio**:

```
qt(.975,26)
```

```
## [1] 2.055529
```

$$\begin{aligned}\mu_1 - \mu_2 &= (510 - 620) \pm 2,056 \sqrt{\frac{20}{20} + \frac{30}{15}} \\ &= -110 \pm 3,561\end{aligned}$$

## Questão 2

- b) Dadas  $\sigma_1^2$  e  $\sigma_2^2$  as variâncias de duas V.A.s com distribuição normal e  $s_1^2$  e  $s_2^2$  as variâncias amostrais, define-se **F** com **distribuição F de Snedecor**:

$$F = \frac{s_1^2 / \sigma_1^2}{s_2^2 / \sigma_2^2} = \frac{s_1^2 \sigma_2^2}{s_2^2 \sigma_1^2}$$

para os graus de liberdade  $df_1 = m - 1$  e  $df_2 = n - 1$

Para construir um IC a variável F deve obedecer à seguinte probabilidade:

$$P(F_{\frac{\alpha}{2}, df_1, df_2} < F < F_{1-\frac{\alpha}{2}, df_1, df_2}) = 1 - \alpha$$

## Questão 2

b) *cont.*

Para tanto:

$$F_{\frac{\alpha}{2}, df_1, df_2} < \frac{s_1^2}{s_2^2} \frac{\sigma_2^2}{\sigma_1^2} < F_{1-\frac{\alpha}{2}, df_1, df_2}$$
$$F_{\frac{\alpha}{2}, df_1, df_2} \frac{s_2^2}{s_1^2} < \frac{\sigma_2^2}{\sigma_1^2} < F_{1-\frac{\alpha}{2}, df_1, df_2} \frac{s_2^2}{s_1^2}$$

Invertendo os termos:

$$\frac{1}{F_{1-\frac{\alpha}{2}, df_1, df_2}} \frac{s_2^2}{s_1^2} < \frac{\sigma_1^2}{\sigma_2^2} < \frac{1}{F_{\frac{\alpha}{2}, df_1, df_2}} \frac{s_2^2}{s_1^2}$$



## Questão 2

b) *cont.*

Substituindo os valores:

$$\frac{1}{F_{0.975,19,14}} \frac{20}{30} < \frac{\sigma_1^2}{\sigma_2^2} < \frac{1}{F_{0.025,19,14}} \frac{20}{30}$$

Utilizando o **RStudio** e a propriedade da distribuição F:

$$F_{\frac{\alpha}{2}, df_1, df_2} = \frac{1}{F_{1-\frac{\alpha}{2}, df_1, df_2}}$$

```
round(qf(0.025,19,14),digits = 3)
```

```
## [1] 0.378
```

## Questão 2

b) *cont.*

$$F_{0.975,19,14} = \frac{1}{F_{0.025,19,14}} = \frac{1}{0.378} = 2.645$$

Logo:

$$\frac{1}{2.645} \frac{20}{30} < \frac{\sigma_1^2}{\sigma_2^2} < \frac{1}{0.378} \frac{20}{30}$$
$$0.251 < \frac{\sigma_1^2}{\sigma_2^2} < 1.754$$

## Questão 3

Sejam  $n = 300$ ,  $\bar{x} = 1660$  e  $s = 90h$ , deseja-se testar:

- $H_0 : \mu_0 = 1690h$
- $H_1 : \mu_0 \neq 1690h$

Trata-se, portanto, de um **Teste Z bicaudal**. Para:

a)  $\alpha = 0.05$

$$\text{Calculadndo } Z = \frac{\bar{x} - \mu_0}{s/\sqrt{n}} = \frac{1660 - 1690}{90/\sqrt{300}} = -5,77$$

Conforme calculado em questão anterior:

$$Z_{0.025} = -1.96 \quad Z_{0.975} = 1.96$$

Como  $Z < Z_{\frac{\alpha}{2}}$  **rejeitamos  $H_0$  com  $\alpha = 0.05$**

## Questão 3

b)  $\alpha = 0.01$

Para o mesmo  $Z = -5.77$  e  $Z_{\frac{\alpha}{2}} = Z_{\frac{0.01}{2}} = Z_{0.005}$

```
qnorm(0.025)
```

```
## [1] -1.959964
```

Como  $Z < Z_{\frac{\alpha}{2}}$  **rejeitamos  $H_0$  com  $\alpha = 0.01$**

## Questão 4

Sejam  $n = 20$ ,  $\bar{x} = 0.06$  e  $s = 0.009$ , deseja-se testar:

- $H_0 : \mu_0 = 0.05$  *pol*
- $H_1 : \mu_0 \neq 0.05$  *pol*

Trata-se, portanto, de um **Teste t bicaudal**. Para:

a)  $\alpha = 0.05$

$$\text{Calculadndo } t = \frac{\bar{x} - \mu_0}{s/\sqrt{n}} = \frac{0.06 - 0.05}{0.009/\sqrt{20}} = 4.969$$

Calculando  $t_{1-\frac{\alpha}{2}, 19}$ :

```
qt(0.975, 19)
```

```
## [1] 2.093024
```

Como  $t > t_{1-\frac{\alpha}{2}}$  **rejeitamos  $H_0$  com  $\alpha = 0.05$**

## Questão 4

b)  $\alpha = 0.01$

Para o mesmo  $t = 4.969$  e  $t_{1-\frac{\alpha}{2},19} = t_{1-\frac{0.01}{2},19} = t_{0.995,19}$ :

```
qt(0.995,19)
```

```
## [1] 2.860935
```

Como  $t > t_{1-\frac{\alpha}{2},19}$  **rejeitamos  $H_0$  com  $\alpha = 0.01$**

## Questão 5

Sejam  $n_a = 20, s_a = 8 (s_a^2 = 64)$  para a turma A e  $n_b = 25, s_b = 10 (s_b^2 = 100)$  para a turma B, deseja-se saber se a variabilidade de B é maior que a de A. Assim temos:

- $H_0 : \sigma_b^2 = \sigma_a^2$
- $H_1 : \sigma_b^2 > \sigma_a^2$

Trata-se, portanto, de um **teste f unicaudal de cauda longa**. Calculando  $f$ :

$$f = \frac{s_b^2}{s_a^2} = \frac{100}{64} = 1.562$$

## Questão 5

a)  $\alpha = 0.01$

Calculando  $f_{0.01,24,19}$ :

```
qf(0.01,24,19,lower.tail = FALSE)
## [1] 2.924866
```

Como  $f > f_{0.01,24,19}$  é **FALSO** falhamos em rejeitar  $H_0$  com  $\alpha = 0.01$

b)  $\alpha = 0.05$

Calculando  $f_{0.05,24,19}$ :

```
qf(0.05,24,19,lower.tail = FALSE)
## [1] 2.114143
```

Como  $f > f_{0.05,24,19}$  é **FALSO** falhamos em rejeitar  $H_0$  com  $\alpha = 0.05$



## Questão 6

Seja a  $X$  uma V.A. com distribuição normal  $N(\mu, \sigma^2)$  cuja fdp é dada por:

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

para  $-\infty < x < \infty$ . A **função de verossimilhança  $L$**  é dada por:

$$L(\mu, \sigma^2; x_1, \dots, x_n) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x_i-\mu)^2}{2\sigma^2}}$$

ou

$$L(\mu, \sigma^2; x_1, \dots, x_n) = (2\pi)^{-n/2} (\sigma^2)^{-n/2} e^{-\frac{1}{2} \sum_{i=1}^n \frac{(x_i-\mu)^2}{\sigma^2}}$$

## Questão 6

Para encontrar o estimador de máxima verossimilhança devemos achar os valores para os quais  $L(\mu, \sigma^2; x_1, \dots, x_n)$  é **máxima**. Inicialmente aplicamos a função **ln**:

$$\ln[L(\mu, \sigma^2; x_1, \dots, x_n)] = -\frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln(\sigma^2) - \frac{1}{2} \sum_{i=1}^n \frac{(x_i - \mu)^2}{\sigma^2}$$

A seguir calculamos a derivada parcial em relação a  $\mu$

$$\begin{aligned} \frac{\partial[\ln L(\mu, \sigma^2; x_1, \dots, x_n)]}{\partial \mu} &= -\frac{2}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)(-1) \\ &= \sum_{i=1}^n \frac{(x_i - \mu)}{\sigma^2} \end{aligned}$$

## Questão 6

Igualando o resultado a zero obtemos:

$$\sum_{i=1}^n \frac{(x_i - \hat{\mu})}{\sigma^2} = 0$$

$$\frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \hat{\mu}) = 0$$

$$\sum_{i=1}^n (x_i - \hat{\mu}) = 0$$

$$\sum_{i=1}^n x_i = n\hat{\mu}$$

$$\hat{\mu} = \frac{\sum_{i=1}^n x_i}{n} = \bar{x}$$

## Questão 6

Dessa forma, é possível que o estimador de máxima verossimilhança para a média populacional seja  $\bar{x}$ . Isto é confirmado se  $\bar{x}$  for considerado um ponto de máximo. Para isto:

$$\begin{aligned}\frac{\partial^2 [\ln L(\mu, \sigma^2; x_1, \dots, x_n)]}{\partial \mu^2} &= \frac{\partial^2}{\partial \mu^2} \left[ \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \hat{\mu}) \right] \\ &= -\frac{n}{\sigma^2} < 0\end{aligned}$$

Concluimos então que  $\bar{x}$  é realmente um ponto de máximo e, por consequência, o estimador de máxima verossimilhança para  $\mu$ .

## Questão 6

Desejamos calcular agora o estimador de máxima verossimilhança para a variância  $\sigma^2$ . Para tanto, derivamos a função  $\ln L[\cdot]$  em relação a  $\sigma^2$ :

$$\frac{\partial[\ln L(\mu, \sigma^2; x_1, \dots, x_n)]}{\partial \sigma^2} = -\frac{n}{2\sigma^2} + \frac{1}{2} \sum_{i=1}^n \left( \frac{x_i - \mu}{\sigma^2} \right)^2$$

Igualando a zero:

$$-\frac{n}{2\sigma^2} + \frac{1}{2} \sum_{i=1}^n \left( \frac{x_i - \mu}{\sigma^2} \right)^2 = 0$$
$$\frac{1}{2} \left[ -\frac{n}{\sigma^2} + \frac{1}{\sigma^4} \sum_{i=1}^n (x_i - \mu)^2 \right] = 0$$

## Questão 6

$$\frac{n}{\sigma^2} = \frac{1}{\sigma^4} \sum_{i=1}^n (x_i - \mu)^2$$
$$\sigma^2 = \frac{\sum_{i=1}^n (x_i - \mu)^2}{n}$$

Multiplicando o segundo termo por  $\frac{n-1}{n-1}$ :

$$\sigma^2 = \frac{\sum_{i=1}^n (x_i - \mu)^2}{n} \cdot \frac{n-1}{n-1}$$
$$\sigma^2 = \frac{n-1}{n} s^2$$

## Questão 6

Dessa forma, é possível que o estimador de máxima verossimilhança para a variância populacional seja  $\frac{n-1}{n}s^2$ . Isto é confirmado se  $\frac{n-1}{n}s^2$  for considerado um ponto de máximo. Para isto:

$$\frac{\partial^2 [\ln L(\mu, \sigma^2; x_1, \dots, x_n)]}{\partial \mu^2} = -\frac{n}{2\sigma^2} < 0$$

Portanto, o estimador de máxima verossimilhança para a  $\sigma^2$  é  $\frac{n-1}{n}s^2$ .

## Questão 7

Sejam  $s_0(t) = -1$  e  $s_1(t) = 1$  e  $n(t) \sim N(0, 1)$ . Para um sinal recebido  $x(t) = s_i(t) + n(t)$ ,  $i = 0, 1$  têm-se as seguintes hipóteses para o sinal que foi transmitido:

- $H_0: s_0(t) \rightarrow x(t) = -1 + n(t)$
- $H_1: s_1(t) \rightarrow x(t) = 1 + n(t)$

Se  $n(t)$  é uma V.A com distribuição Normal e  $s_i(t)$  é uma função constante, logo  $x(t)$  também é uma V.A. com distribuição Normal. Reformulando as hipóteses:

- $H_0: f(x|H_0) \rightarrow f_N(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{(x+1)^2}{2}}, \forall X \sim N(-1, 1)$
- $H_1: f(x|H_1) \rightarrow f_N(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{(x-1)^2}{2}}, \forall X \sim N(1, 1)$



## Questão 8

Seja a **distribuição Gaussiana Multivariada** dada por:

$$f(\mathbf{x}|\boldsymbol{\mu}, \mathbf{C}) = \frac{1}{(2\pi)^{D/2} \det(\mathbf{C})^{1/2}} \exp\left(-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^T \mathbf{C}^{-1}(\mathbf{x} - \boldsymbol{\mu})\right)$$

onde:

- $D$  - *espaço  $D$ -dimensional*
- $\mathbf{C}$  - *matriz de covariância*
- $\boldsymbol{\mu}$  - *vetor de médias*
- $\mathbf{x}$  - *vetor de V.A. independentes*

## Questão 8

Da definição de **matriz de covariância**, para  $\mathbf{x} = [x_1, x_2]$  e  $\boldsymbol{\mu} = [\mu_1, \mu_2]$ , temos:

$$\begin{aligned}\mathbf{C} &= E[(\mathbf{x} - \boldsymbol{\mu})^T (\mathbf{x} - \boldsymbol{\mu})] \\ &= E \left[ \begin{bmatrix} x_1 - \mu_1 \\ x_2 - \mu_2 \end{bmatrix} \begin{bmatrix} x_1 - \mu_1 & x_2 - \mu_2 \end{bmatrix} \right] \\ &= E \left[ \begin{bmatrix} (x_1 - \mu_1)(x_1 - \mu_1) & (x_1 - \mu_1)(x_2 - \mu_2) \\ (x_1 - \mu_1)(x_2 - \mu_2) & (x_2 - \mu_2)(x_2 - \mu_2) \end{bmatrix} \right] \\ &= E \left[ \begin{bmatrix} (x_1 - \mu_1)^2 & (x_1 - \mu_1)(x_2 - \mu_2) \\ (x_1 - \mu_1)(x_2 - \mu_2) & (x_2 - \mu_2)^2 \end{bmatrix} \right] \\ \mathbf{C} &= \begin{bmatrix} \sigma_1^2 & \sigma_{12} \\ \sigma_{21} & \sigma_2^2 \end{bmatrix}\end{aligned}$$

onde  $\sigma_{12}$  é a covariância entre  $x_1$  e  $x_2$ .

## Questão 8

Como  $x_1$  e  $x_2$  são V.A. independentes,  $\sigma_{12} = \sigma_{21} = 0$ . Assim:

$$\mathbf{C} = \begin{bmatrix} \sigma_1^2 & 0 \\ 0 & \sigma_2^2 \end{bmatrix}$$

$$\mathbf{C}^{-1} = \begin{bmatrix} \frac{1}{\sigma_1^2} & 0 \\ 0 & \frac{1}{\sigma_2^2} \end{bmatrix}$$

Para esboçar o gráfico de distribuição dos dados no plano  $x_1x_2$  devemos calcular o valor de  $(\mathbf{x} - \boldsymbol{\mu}_i)^T \mathbf{C}^{-1}(\mathbf{x} - \boldsymbol{\mu}_i)$  para algum valor de  $k$  constante. Assim:

$$(\mathbf{x} - \boldsymbol{\mu}_i)^T \mathbf{C}^{-1}(\mathbf{x} - \boldsymbol{\mu}_i) = k$$

## Questão 8

Tomando  $\boldsymbol{\mu}_1 = [-1 \ 0]^T$ ,  $\mathbf{x} = [x_1 \ x_2]$  e  $k = 1$ :

$$[x_1 + 1 \ x_2] \begin{bmatrix} \frac{1}{\sigma_1^2} & 0 \\ 0 & \frac{1}{\sigma_2^2} \end{bmatrix} \begin{bmatrix} x_1 + 1 \\ x_2 \end{bmatrix} = 1$$

$$\frac{(x_1 + 1)^2}{\sigma_1^2} + \frac{x_2^2}{\sigma_2^2} = 1$$

A equação acima mostra que o gráfico é uma elipse no plano  $x_1x_2$ . Para o caso em questão com variâncias iguais:

$$\mathbf{C} = 0.5 \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} = \begin{bmatrix} 0.5 & 0 \\ 0 & 0.5 \end{bmatrix}$$

## Questão 8

Logo:

$$\frac{(x_1 + 1)^2}{0.5} + \frac{x_2^2}{0.5} = 1$$

$$[x_1 + 1]^2 + x_2^2 = 0.5$$

$$[x_1 - (-1)]^2 + (x_2 - 0)^2 = 0.5$$

Para variâncias iguais a equação se transforma numa equação de um círculo de centro  $[-1,0]$  e raio 0.5. O mesmo raciocínio vale para  $\mu_2 = [1 \ 0]^T$ , onde encontramos o centro do círculo em  $[1,0]$ .

Generalizando para a questão:

$$\forall k > 0, \exists [(x_1, x_2) \in \mathbf{x}, (\mu_1, \mu_2) \in \mu] \rightarrow (x_1 - \mu_1)^2 + (x_2 - \mu_2)^2 = k,$$

onde  $k = \sigma^2$ .

## Questão 8

Com o auxílio do MATLAB, plotamos os gráficos para  $\mu_1$  e  $\mu_2$ :




Figura:  $\mu_1$

## Questão 8




Figura:  $\mu_2$

## Questão 8




Figura:  $\mu_1$  e  $\mu_2$



## Questão 8

Calculando a função de **Máxima Verossimilhança(ML)**  $\Lambda_{ML}(x)$ :

$$\Lambda_{ML}(x) = \frac{f(\mathbf{x}|C_2)}{f(\mathbf{x}|C_1)} \underset{C_1}{>} \underset{C_2}{<} \frac{f(C_1)}{f(C_2)}$$

Tomando  $C_1$  e  $C_2$  como equiprováveis temos:  $\Lambda_{ML}(x)$ :

$$\Lambda_{ML}(x) = \frac{f(\mathbf{x}|C_2)}{f(\mathbf{x}|C_1)} \underset{C_1}{>} \underset{C_2}{<} 1$$

## Questão 8

Assim:

$$\begin{aligned}\Lambda_{ML}(x) &= \frac{\frac{1}{(2\pi)^{D/2} \det(\mathbf{C})^{1/2}} \exp(-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_2)^T \mathbf{C}^{-1}(\mathbf{x} - \boldsymbol{\mu}_2))}{\frac{1}{(2\pi)^{D/2} \det(\mathbf{C})^{1/2}} \exp(-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_1)^T \mathbf{C}^{-1}(\mathbf{x} - \boldsymbol{\mu}_1))} \underset{C_1}{>} \underset{C_2}{<} 1 \\&= \frac{\exp(-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_2)^T \mathbf{C}^{-1}(\mathbf{x} - \boldsymbol{\mu}_2))}{\exp(-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_1)^T \mathbf{C}^{-1}(\mathbf{x} - \boldsymbol{\mu}_1))} \underset{C_1}{>} \underset{C_2}{<} 1 \\&= \exp(-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_2)^T \mathbf{C}^{-1}(\mathbf{x} - \boldsymbol{\mu}_2) + \frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_1)^T \mathbf{C}^{-1}(\mathbf{x} - \boldsymbol{\mu}_1)) \\ \Lambda_{ML}(x) &= \exp - \frac{1}{2} \{ (\mathbf{x} - \boldsymbol{\mu}_2)^T \mathbf{C}^{-1}(\mathbf{x} - \boldsymbol{\mu}_2) - [(\mathbf{x} - \boldsymbol{\mu}_1)^T \mathbf{C}^{-1}(\mathbf{x} - \boldsymbol{\mu}_1)] \}\end{aligned}$$

## Questão 8

Calculando o **logaritmo de Verossimilhança**  $\delta_{ML}(\Lambda_{ML}(x))$ :

$$\begin{aligned}\ln[\Lambda_{ML}(x)] &= \ln e^{-\frac{1}{2}\{(x-\mu_2)^T C^{-1}(x-\mu_2) - [(x-\mu_1)^T C^{-1}(x-\mu_1)]\}} \\ &= -\frac{1}{2}\{(x-\mu_2)^T C^{-1}(x-\mu_2) - [(x-\mu_1)^T C^{-1}(x-\mu_1)]\}\end{aligned}$$

Expandindo os produtos:

$$\begin{aligned}\delta_{ML}(\Lambda_{ML}(x)) &= -\frac{1}{2}\{x^T C^{-1}x - x^T C^{-1}\mu_2 - \mu_2^T C^{-1}x - \mu_2^T C^{-1}\mu_2 \\ &\quad - [x^T C^{-1}x - x^T C^{-1}\mu_1 - \mu_1^T C^{-1}x + \mu_1^T C^{-1}\mu_1]\}\end{aligned}$$

## Questão 8

$$\begin{aligned}\delta_{ML}(\Lambda_{ML}(x)) &= -\frac{1}{2}\{\cancel{x^T C^{-1} x} - x^T C^{-1} \mu_2 - \mu_2^T C^{-1} x + \mu_2^T C^{-1} \mu_2 \\ &\quad \cancel{-x^T C^{-1} x} + x^T C^{-1} \mu_1 + \mu_1^T C^{-1} x - \mu_1^T C^{-1} \mu_1\} \\ &= -\frac{1}{2}\{-\cancel{2}\mu_2^T C^{-1} x + \cancel{2}\mu_1^T C^{-1} x - [\mu_1^T C^{-1} \mu_1 \\ &\quad - \mu_2^T C^{-1} \mu_2]\} \\ &= \mu_2^T C^{-1} x - \mu_1^T C^{-1} x + \frac{1}{2}[\mu_1^T C^{-1} \mu_1 \\ &\quad - \mu_2^T C^{-1} \mu_2] \\ &= (\mu_2^T C^{-1} - \mu_1^T C^{-1})x + \frac{1}{2}[\mu_1^T C^{-1} \mu_1 - \mu_2^T C^{-1} \mu_2]\end{aligned}$$

## Questão 8

Fazendo:

$$\mathbf{w}^T = (\mu_2^T \mathbf{C}^{-1} - \mu_1^T \mathbf{C}^{-1})$$

e:

$$\mathbf{w}_0 = \frac{1}{2}[\mu_1^T \mathbf{C}^{-1} \mu_1 - \mu_2^T \mathbf{C}^{-1} \mu_2]$$

temos:

$$\ln[\Lambda_{ML}(x)] = \mathbf{w}^T \mathbf{x} + \mathbf{w}_0$$

o que, pela linearidade em  $\mathbf{x}$  da nova equação, configura a equação de um **hiperplano**.